



# Capacitação em Inteligência Artificial e Aplicações

---

## Classificadores Supervisionados: Classificação Bayesiana

- Prof. Gerson Vieira Albuquerque Neto
- Prof. Rodrigo Carvalho Souza Costa
- Prof. Yves Augusto Romero



UNIVERSIDADE  
ESTADUAL DO CEARÁ



MINISTÉRIO DA  
CIÊNCIA, TECNOLOGIA  
E INOVAÇÃO





# IA

## Planejamento da Disciplina


D	S	T	Q	Q	S	S
26	27 Introdução ao curso	28 Áreas e aplicações de IA	29 Tipos e definições de Inteligência artificial	30 Revisão de álgebra e probabilidade	31 Laboratório Python 1	1
2	3 Introdução aos classificadores supervisionados	4 Aula teórica Naive BaSim	5 Aula prática Naive BaSim	6 Feriado Semana Santa	7 Feriado Semana Santa	8
9	10 KNN + Métricas de Avaliação	11 Regressão Linear e e Introdução à árvores de decisão	12 Prática Regressão Lienar + Árvores de Decisão	13 Introdução à Clusterização + KMédias	14 Introdução ao PCA / prática com classificadores já implementados	15
16	17 Introdução ao Perceptron Simples – Prática	18 Teoria MLP / Aplicação scilearn	19 Introdução ao DeepLearning	20 Uso de biblioteca DeepLearning	21 Feriado Tiradentes	28
23	24 Introdução ao TensorFlow / Keras	25 Introdução ao Pytorch	26 Tensorflow for android	27	28	29



- Após a conclusão deste módulo, você será capaz de:
  - Compreensão de algoritmos de aprendizado baseado em similaridade.
  - Compreender como avaliar a eficiência do classificador







# Classificadores Supervisionados: Classificação Bayesiana



- Classificação por k-NN
- Avaliação dos modelos de aprendizagem
- Formas de medir o erro



UNIVERSIDADE  
ESTADUAL DO CEARÁ



MINISTÉRIO DA  
CIÊNCIA, TECNOLOGIA  
E INOVAÇÃO






# IA

## Algoritmo k-NN

- O algoritmo de classificação k-NN é um método teoricamente maduro e um dos algoritmos de aprendizado de máquina mais simples.
- De acordo com este método, se a maioria das k amostras mais semelhantes a uma amostra (vizinhos mais próximos no espaço próprio) pertencem a uma categoria específica, esta amostra também pertence a esta categoria.




A categoria da amostra ? varia de acordo o número dos nós mais próximos.




# IA

## Medidas de Distância




Euclidiana

$$D(P_x, P_y) = \sqrt{\sum_{c=1}^n (x_i - y_i)^2}$$



Manhatan

$$(P_x, P_y) = \sum_{c=1}^n |x_i - y_i|$$



Mahalanobis


$$(P_x, P_y) = \sqrt{(x - \mu)S^{-1}(x - \mu)}$$



# IA

# k-NN

- Como o resultado da previsão é determinado com base no número e pesos dos vizinhos no conjunto de treinamento, o algoritmo k-NN tem uma lógica simples.
- k-NN é um método não paramétrico que geralmente é usado em conjuntos de dados com limites de decisão irregulares.
  - O algoritmo k-NN geralmente adota o método de votação majoritária para predição de classificação e o método de valor médio para predição de regressão.
- k-NN requer um grande número de cálculos.








# IA


## Ajuste no valor de K

- Geralmente, um valor k maior reduz o impacto do ruído na classificação, mas ofusca a fronteira entre as classes.



- A fronteira de decisão torna-se mais suave à medida que o número de k aumenta.
- À medida que o número k aumenta e tende ao infinito, todos os pontos de dados acabarão por se tornar todos azuis ou vermelhos.





# Classificadores Supervisionados: Classificação Bayesiana



- Classificação por k-NN
- **Avaliação dos modelos de aprendizagem**
- Formas de medir o erro



UNIVERSIDADE  
ESTADUAL DO CEARÁ



MINISTÉRIO DA  
CIÊNCIA, TECNOLOGIA  
E INOVAÇÃO





# IA

## Avaliação dos modelos: Capacidade de generalização

- O objetivo do aprendizado de máquina é que o modelo obtido após o aprendizado tenha um bom desempenho em novas amostras, não apenas em amostras usadas para treinamento.
- A capacidade de aplicar um modelo a novas amostras é chamada de generalização ou robustez.



Dados usados para treinamento



Novas amostras



# IA

## Avaliação dos modelos: Erro


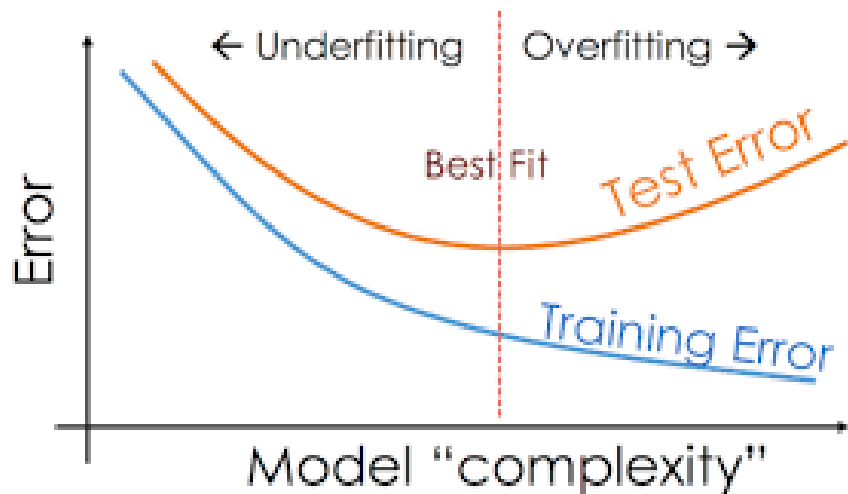
- **Erro:** diferença entre o resultado da amostra previsto pelo modelo obtido após a aprendizagem e o resultado real da amostra.
  - **Erro de treinamento:** erro que você obtém ao executar o modelo nos dados de treinamento.
  - **Erro de generalização:** erro que você obtém ao executar o modelo em novos exemplos. Obviamente, preferimos um modelo com um erro de generalização menor.




# IA

## Avaliação dos modelos: Capacidade do modelo


- **Underfitting**: ocorre quando o modelo ou o algoritmo não ajusta os dados bem o suficiente.
- **Overfitting**: ocorre quando o erro de treinamento do modelo obtido após o aprendizado é pequeno, mas o erro de generalização é grande (baixa capacidade de generalização).



underfitting



correcto



overfitting






# IA

## Avaliação dos modelos: complexidade do modelo

- Também conhecido como capacidade de ajuste do modelo
  - Quando a capacidade se adapta à complexidade da tarefa e à quantidade de dados de treinamento fornecidos, o efeito do algoritmo geralmente é ideal.
  - Modelos com capacidade insuficiente não podem resolver tarefas complexas e pode ocorrer um ajuste insuficiente.
  - Um modelo de alta capacidade pode resolver tarefas complexas, mas o excesso de ajuste pode ocorrer se a capacidade for maior do que a exigida por uma tarefa.




Underfitting  
Nem todos os recursos são aprendidos.

Good fitting

Overfitting  
Ruídos são aprendidos.




- Erro total da predição final =  $\text{Bias}^2 + \text{Variância} + \text{Erro irreduzível}$
- Geralmente, o erro de predição pode ser dividido em dois tipos:
  - Erro causado por "viés" ou Bias
  - Erro causado por "variância"
- Variância:
  - Deslocamento do resultado da previsão do valor médio
  - Erro causado pela sensibilidade do modelo a pequenas flutuações no conjunto de treinamento
- Bias:
  - Diferença entre o valor de previsão esperado (ou médio) e o valor correto que estamos tentando prever.





# IA

## Relação entre variância e Bias




- As combinações de variância e viés são as seguintes:
  - Baixo viés e baixa variância – > Bom modelo
  - Baixo viés e alta variância
  - Alto viés e baixa variância
  - Alto viés e alta variância – > Modelo ruim
- Idealmente, queremos um modelo que possa capturar com precisão as regras nos dados de treinamento e resumir os dados invisíveis (novos dados).
- No entanto, geralmente é impossível para o modelo concluir as duas tarefas ao mesmo tempo.




# IA

## Complexidade e erro do modelo

- À medida que a complexidade do modelo aumenta, o erro de treinamento diminui.
- À medida que a complexidade do modelo aumenta, o erro de teste diminui até um certo ponto e, em seguida, aumenta na direção inversa, formando uma curva convexa.







# Classificadores Supervisionados: Classificação Bayesiana



- Classificação por k-NN
- Avaliação dos modelos de aprendizagem
- **Formas de medir o erro**



UNIVERSIDADE  
ESTADUAL DO CEARÁ



MINISTÉRIO DA  
CIÊNCIA, TECNOLOGIA  
E INOVAÇÃO





# IA

## Avaliação de Desempenho: ML por Regressão

- Quanto mais próximo de zero é o Erro Absoluto Médio (**MAE – Mean Absolute Error**), melhor é o ajuste do modelo aos dados de treinamento.

$$MAE = \frac{1}{m} \sum_{i=1}^m |y_i - \hat{y}_i|$$

- Erro Quadrático Médio (**MSE - Mean Square Error**)

$$MSE = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2$$

- O valor de  **$R^2$**  varia no intervalo de  $(-\infty, 1]$ . Um valor grande indica que o modelo fez um bom ajuste aos dados de treinamento e é calculado a partir do **RSS**.
- O Valor de RSS indica a diferença entre o valor predito e o valor da amostra treinada.


$$R^2 = 1 - \frac{RSS}{TSS} = 1 - \frac{\sum_{i=1}^m (y_i - \hat{y}_i)^2}{\sum_{i=1}^m (y_i - \bar{y}_i)^2}$$



# IA

## Avaliação de Desempenho: ML por Classificação

- Exemplo:
  - Detecção de Intrusão. Detecta casos **positivos de intrusão** e notifica o administrador de rede sobre o
- Comportamento normal (Acertos)
  - Tráfego suspeito detectado.
  - Tráfego **legítimo** que o IDS analisa como sendo **normal**.
- Falhas de detecção (Erros)
  - Tráfego suspeito não detectado.
  - Tráfego **legítimo** que o IDS analisa como sendo **suspeito**.





# IA

## Avaliação de Desempenho: ML por Classificação

- Termos e definições:

- **P**: positivo, indicando o número de casos positivos reais nos dados.
- **N**: negativo, indicando o número de casos reais negativos nos dados.
- **TP**: verdadeiro positivo, indicando o número de casos positivos que são corretamente classificados pelo classificador.
- **TN**: verdadeiro negativo, indicando o número de casos negativos que são corretamente classificados pelo classificador.
- **PF**: falso positivo, indicando o número de casos positivos que são classificados incorretamente pelo classificador.
- **FN**: falso negativo, indicando o número de casos negativos que são classificados incorretamente pelo classificador.

Valor Estimado \ Valor Real	Sim	Não	Total
Positivo	$TP$	$FN$	$P$
Negativo	$FP$	$TN$	$N$
Total	$P'$	$N'$	$P + N$

Matriz de Confusão

	TRUE	FALSE
POSITIVE	True-Positive (Rule matched and attack present)	False-Positive (Rule matched and no attack present)
NEGATIVE	True-Negative (No rule matched and no attack present)	False-Negative (No rule matched and attack present)





# IA

## Avaliação de Desempenho: Métricas calculadas a partir da matriz de confusão

Medida	Relação
Acurácia ou taxa de reconhecimento	$\frac{TP + TN}{P + N}$
Taxa de erro e taxa de classificação incorreta	$\frac{FP + FN}{P + N}$
Sensibilidade, taxa positiva verdadeira e recordação (recall)	$\frac{TP}{P}$
Especificidade e taxa de verdadeiro negativo	$\frac{TN}{N}$
Precisão	$\frac{TP}{TP + FP}$
$F_1$ , média harmônica da taxa de recordação e precisão	$\frac{2 \times precision \times recall}{precision + recall}$
$F_\beta$ , onde $\beta$ é um número real não negativo	$\frac{(1 + \beta^2) \times precision \times recall}{\beta^2 \times precision + recall}$




- Treinamos um modelo de aprendizado de máquina para identificar se o objeto em uma imagem é um gato.
  - Agora usamos 200 imagens para verificar o desempenho do modelo.
  - Entre as 200 imagens, objetos em 170 imagens são gatos, enquanto outros não.
  - O resultado de identificação do modelo é que os objetos em 160 imagens são gatos, enquanto outros não são
- Medidas
  - Precisão:  $P = \frac{TP}{TP+FP} = \frac{140}{140+20} = 87.5\%$
  - Taxa de Recordação:  $R = \frac{TP}{P} = \frac{140}{170} = 82.4\%$
  - Acurácia:  $ACC = \frac{TP+TN}{P+N} = \frac{140+10}{170+30} = 75\%$



# IA

## Avaliação de Desempenho: Matriz de Confusão

- Matriz de confusão: uma tabela de dimensões  $m \times m$ .
- $CM_{i,j}$  das primeiras  $m$  linhas e  $m$  colunas indica o número de casos que realmente pertencem à classe  $i$ , mas que são classificados na classe  $j$  pelo classificador.
  - Idealmente, para um classificador de alta precisão, a maioria dos valores de previsão deve estar localizada na diagonal de  $CM_{1,1}$  a  $CM_{m,m}$  da tabela, enquanto os valores fora da diagonal são 0 ou próximos de 0.
  - Ou seja, FN e FP estão próximos de 0.





# IA

## Avaliação de Desempenho: Métricas calculadas a partir da matriz de confusão

Medida	Relação
Acurácia ou taxa de reconhecimento da	$\frac{\sum_{c=1}^m TP_c + \sum_{c=1}^m TN_c}{\sum_{c=1}^m P_c + N_c}$
Sensibilidade, taxa positiva verdadeira e recordação (recall) da classe C	$\frac{TP_c}{P_c}$
Precisão da classe C	$\frac{TP_c}{TP_c + FP_c}$
Macroprecisão	$\frac{\sum_{c=1}^m Precisão_c}{\sum_{c=1}^m P_c + N_c}$
Microprecisão	$\frac{\sum_{c=1}^m TP_c}{\sum_{c=1}^m P_c + N_c}$






## Na próxima aula

---

- Vamos compreender como funciona um algoritmo de árvore de decisão



UNIVERSIDADE  
ESTADUAL DO CEARÁ



MINISTÉRIO DA  
CIÊNCIA, TECNOLOGIA  
E INOVAÇÃO



# Dúvidas?

Módulo de Inteligência Artificial



UNIVERSIDADE  
ESTADUAL DO CEARÁ



Instituto Iracema  
PESQUISA E INOVAÇÃO



MINISTÉRIO DA  
CIÊNCIA, TECNOLOGIA  
E INOVAÇÃO

