



# Capacitação em Inteligência Artificial e Aplicações

---

## Aprendizado Não Supervisionado:

- Prof. Gerson Vieira Albuquerque Neto
- Prof. Rodrigo Carvalho Souza Costa
- Prof. Yves Augusto Romero



UNIVERSIDADE  
ESTADUAL DO CEARÁ



MINISTÉRIO DA  
CIÊNCIA, TECNOLOGIA  
E INOVAÇÃO





# IA

## Planejamento da Disciplina

D	S	T	Q	Q	S	S
26	27 Introdução ao curso	28 Áreas e aplicações de IA	29 Tipos e definições de Inteligência artificial	30 Revisão de álgebra e probabilidade	31 Laboratório Python 1	1
2	3 Introdução aos classificadores supervisionados	4 Aula teórica Naive Bayes	5 Aula prática Naive Bayes	6 Feriado Semana Santa	7 Feriado Semana Santa	8
9	10 KNN + Métricas de Avaliação	11 Regressão Linear e Introdução à árvores de decisão	12 Prática Regressão Linear + Árvores de Decisão	13 Feriado	14 Introdução à Clusterização + KMédias	15
16	17 Falta de Energia Campus Fortaleza	18 PCA / Hiperparâmetros	19 Introdução ao Perceptron Simples – Prática	20 MLP	21 Feriado Tiradentes	28
23	24 Introdução ao DeepLearning	25 Introdução ao TensorFlow / Keras	26 Introdução ao Pytorch	27 Tensorflow for android	28	29



- Após a conclusão deste módulo, você será capaz de:
  - Compreender o funcionamento de métodos de redução de características
  - Compreender o conceito de Hiperparâmetros







## Aprendizado Não Supervisionado:

- Redução de dimensionalidade
- Hiperparâmetros



UNIVERSIDADE  
ESTADUAL DO CEARÁ



MINISTÉRIO DA  
CIÊNCIA, TECNOLOGIA  
E INOVAÇÃO







# IA

## Redução de Dimensionalidade

- Transformação de dados de um espaço de alta dimensão em um espaço de baixa dimensão
- Idealmente perto de sua dimensão intrínseca.
- Métodos
  - Seleção de atributos
  - Projeção de atributos








# IA

## Análise de Componentes Principais PCA - Principal Component Analysis

- O PCA é frequentemente usado para reduzir a dimensionalidade de grandes conjuntos de dados, transformando um grande conjunto de variáveis em um menor que ainda contém a maioria das informações no grande conjunto.






# IA

## Componentes Principais

- Consiste em uma técnica estatística que realiza uma transformação linear de um conjunto de variáveis originais em um menor conjunto com variáveis descorrelacionadas, representando a maior parte da informação do conjunto de dados originais.



- A Componente Principal é o arranjo que melhor representa a distribuição dos dados (**linha vermelha**) e a Componente secundária é perpendicular a componente principal (**linha azul**).





- O c-componente principal é encontrado a partir da transformação do espaço original através do autovetor  $E_c = (e_1, e_2, \dots, e_n)$  associado ao c-maior autovalor da matriz de covariância  $C_X$ , ou seja:

$$y = x \cdot E_c.$$

X1 →  
X2 →  
X3 →  
⋮  
Xp →

*P - variáv*

Calcular matriz  
de covariância  
 $C_X$



Encontrar os  
autovalores  
 $\Lambda$



Encontrar os c  
auto-vetores  
 $E_c$



Seleção de  
novas  
características

→ Y1  
→ Y2  
→ Y3  
⋮  
→ Yp

*P - componentes  
Principais*





- A matriz de covariância ( $C_X$ ) do espaço característico X é definida como:

$$C_X = \sum_{i=1}^m (x_i - \bar{x}) (x_i - \bar{x})^T$$

$$C = \begin{pmatrix} cov(x, x) & cov(x, y) & cov(x, z) \\ cov(y, x) & cov(y, y) & cov(y, z) \\ cov(z, x) & cov(z, y) & cov(z, z) \end{pmatrix}$$

- Em que:
  - Os componentes  $c_{ij}$  da matriz de covariância ( $C_X$ ) representam a covariância entre as variáveis  $i$  e  $j$ .
  - Quando duas características  $j$  e  $k$  dos dados estão correlacionadas, sua covariância é nula ( $c_{jk} = c_{kj} = 0$ ).
- Escolhendo os autovetores associados aos maiores autovalores, há a menor perda possível de informação neste novo espaço característico



# IA

## Calculando os autovalores e autovetores de $C_x$

- Para calcular os autovalores  $\lambda$  da matriz  $C_x$  deve-se resolver a equação característica:

$$\det(C_x - \lambda I) = 0$$

- Sabendo que para cada autovalor  $\lambda_i$  encontrado, resolvemos o sistema linear  $(C_x - \lambda I)v = 0$  para calcular o autovetor  $v$  associado ao autovalor  $\lambda_i$

$\lambda_i$

x	y
2	3
2	4
3	4
4	4
5	4
5	5
6	6
6	7
7	7
8	7

$\bar{x}$	$\bar{y}$
4,8	5,1

$\bar{x}$

37,6	25,2
25,2	20,9

$C_x$

$37,6 - \lambda$	25,2
25,2	$20,9 - \lambda$

$C_x - \lambda I$

$$\lambda^2 - 58,5\lambda + 150,8 = 0$$

$$\det(C_x - \lambda I) = 0$$



# IA

## Calculando os autovalores e autovetores de $C_x$

- Para calcular os autovalores  $\lambda$  da matriz  $C_x$  deve-se resolver a equação característica:

$$\det(C_x - \lambda I) = 0$$

- Sabendo que para cada autovalor  $\lambda_i$  encontrado, resolvemos o sistema linear  $(C_x - \lambda I)v = 0$  para calcular o autovetor  $v$  associado ao autovalor  $\lambda_i$

$x$	$y$
2	3
2	4
3	4
4	4
5	4
5	5
6	6
6	7
7	7
8	7

55,7974	0
0	2,70264

*autovalores*

$$E_1 = 0.81071949x - 0.58543481y$$


$$E_2 = 0.58543481x + 0.81071949y$$




# IA

## Exemplo

$$E_1 = 0.81071949x - 0.58543481y$$
$$E_2 = 0.58543481x + 0.81071949y$$







## Aprendizado Não Supervisionado:

- Redução de dimensionalidade
- **Hiperparâmetros**



UNIVERSIDADE  
ESTADUAL DO CEARÁ



MINISTÉRIO DA  
CIÊNCIA, TECNOLOGIA  
E INOVAÇÃO






# IA

## Parâmetros e hiperparâmetros em modelos

- O modelo contém não apenas parâmetros, mas também hiperparâmetros.
- O objetivo é permitir que o modelo aprenda os parâmetros ideais.
  - Os parâmetros são aprendidos automaticamente por modelos.
  - Os hiperparâmetros são definidos manualmente.





- Frequentemente usado em processos de estimativa de parâmetros de modelo.
- Muitas vezes especificado pelo praticante.
- Muitas vezes pode ser definido usando heurísticas.
- Muitas vezes ajustado para um determinado problema de modelagem preditiva.

Os hiperparâmetros do modelo são configurações externas dos modelos.

- $\lambda$  durante a regressão de Lasso/Ridge
- Taxa de aprendizado para treinar uma rede neural, número de iterações, tamanho do lote, função de ativação e número de neurônios
- $C$  e  $\sigma$  em máquinas vetoriais de suporte (SVM)
- $K$  em k-vizinho mais próximo (KNN)
- Número de árvores em uma floresta aleatória

Hiperparâmetros comuns do modelo



Procedimento para  
pesquisar  
hiperparâmetros

1. Dividir um conjunto de dados em um conjunto de treinamento, conjunto de validação e conjunto de testes.
2. Otimização dos parâmetros do modelo usando o conjunto de treinamento com base nos indicadores de desempenho do modelo.
3. Procurar os hiperparâmetros do modelo usando o conjunto de validação com base nos indicadores de desempenho do modelo.
4. Execute as etapas 2 e 3 alternadamente. Finalmente, determine os parâmetros e hiperparâmetros do modelo e avalie o modelo usando o conjunto de testes.

Algoritmo de busca  
(etapa 3)

- Busca em grade
- Busca aleatória
- Busca inteligente heurística
- Busca bayesiana






# IA

## Método de pesquisa de hiperparâmetros - Pesquisa em grade

- A pesquisa em grade tenta pesquisar exaustivamente todas as combinações de hiperparâmetros possíveis para formar uma grade de valores de hiperparâmetros.
- Na prática, o intervalo de valores de hiperparâmetros a serem pesquisados é especificado manualmente.
- A pesquisa em grade é um método caro e demorado.
- Este método funciona bem quando o número de hiperparâmetros é relativamente pequeno. Portanto, é aplicável a algoritmos de aprendizado de máquina em geral, mas inaplicável a redes neurais (consulte a parte de aprendizado profundo).



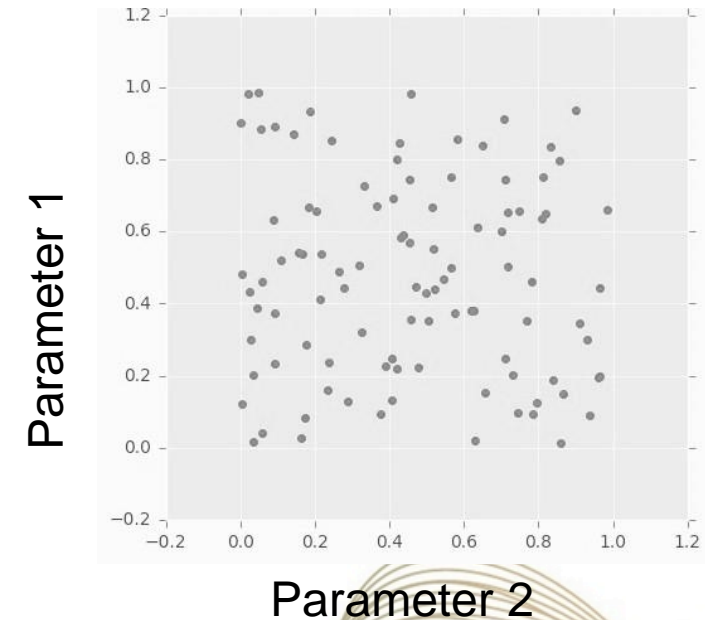


# IA

## Método de pesquisa de hiperparâmetros - Pesquisa aleatória

- Quando o espaço de pesquisa de hiperparâmetro é grande, a pesquisa aleatória é melhor do que a pesquisa em grade.
- Na pesquisa aleatória, cada configuração é amostrada a partir da distribuição de possíveis valores de parâmetros, na tentativa de encontrar o melhor subconjunto de hiperparâmetros.
- Nota:
  - A pesquisa é realizada dentro de um intervalo grosseiro, que será reduzido com base em onde o melhor resultado aparece.
  - Alguns hiperparâmetros são mais importantes do que outros, e o desvio de pesquisa será afetado durante a pesquisa aleatória.

Random search





# Classificadores Supervisionados: próxima aula

- Prática PCA



UNIVERSIDADE  
ESTADUAL DO CEARÁ



MINISTÉRIO DA  
CIÊNCIA, TECNOLOGIA  
E INOVAÇÃO





# Dúvidas?

Módulo de Inteligência Artificial



UNIVERSIDADE  
ESTADUAL DO CEARÁ



Instituto Iracema  
PESQUISA E INOVAÇÃO



Softex

MINISTÉRIO DA  
CIÊNCIA, TECNOLOGIA  
E INOVAÇÃO

GOVERNO FEDERAL  
**BRASIL**  
UNIÃO E RECONSTRUÇÃO