



# Capacitação em Inteligência Artificial e Aplicações

---

## Deep Learning

- Prof. Gerson Vieira Albuquerque Neto
- Prof. Rodrigo Carvalho Souza Costa
- Prof. Yves Augusto Romero



UNIVERSIDADE  
ESTADUAL DO CEARÁ



MINISTÉRIO DA  
CIÊNCIA, TECNOLOGIA  
E INOVAÇÃO





# IA

## Planejamento da Disciplina

D	S	T	Q	Q	S	S
26	27 Introdução ao curso	28 Áreas e aplicações de IA	29 Tipos e definições de Inteligência artificial	30 Revisão de álgebra e probabilidade	31 Laboratório Python 1	1
2	3 Introdução aos classificadores supervisionados	4 Aula teórica Naive Bayes	5 Aula prática Naive Bayes	6 Feriado Semana Santa	7 Feriado Semana Santa	8
9	10 KNN + Métricas de Avaliação	11 Regressão Linear e Introdução à árvores de decisão	12 Prática Regressão Linear + Árvores de Decisão	13 Feriado	14 Introdução à Clusterização + KMédias	15
16	17 Falta de Energia Campus Fortaleza	18 PCA / Hiperparâmetros	19 Introdução ao Perceptron Simples – Prática	20 MLP	21 Feriado Tiradentes	28
23	24 Introdução ao DeepLearning	25 Introdução ao TensorFlow / Keras	26 Introdução ao Pytorch	27 Tensorflow for android	28	29



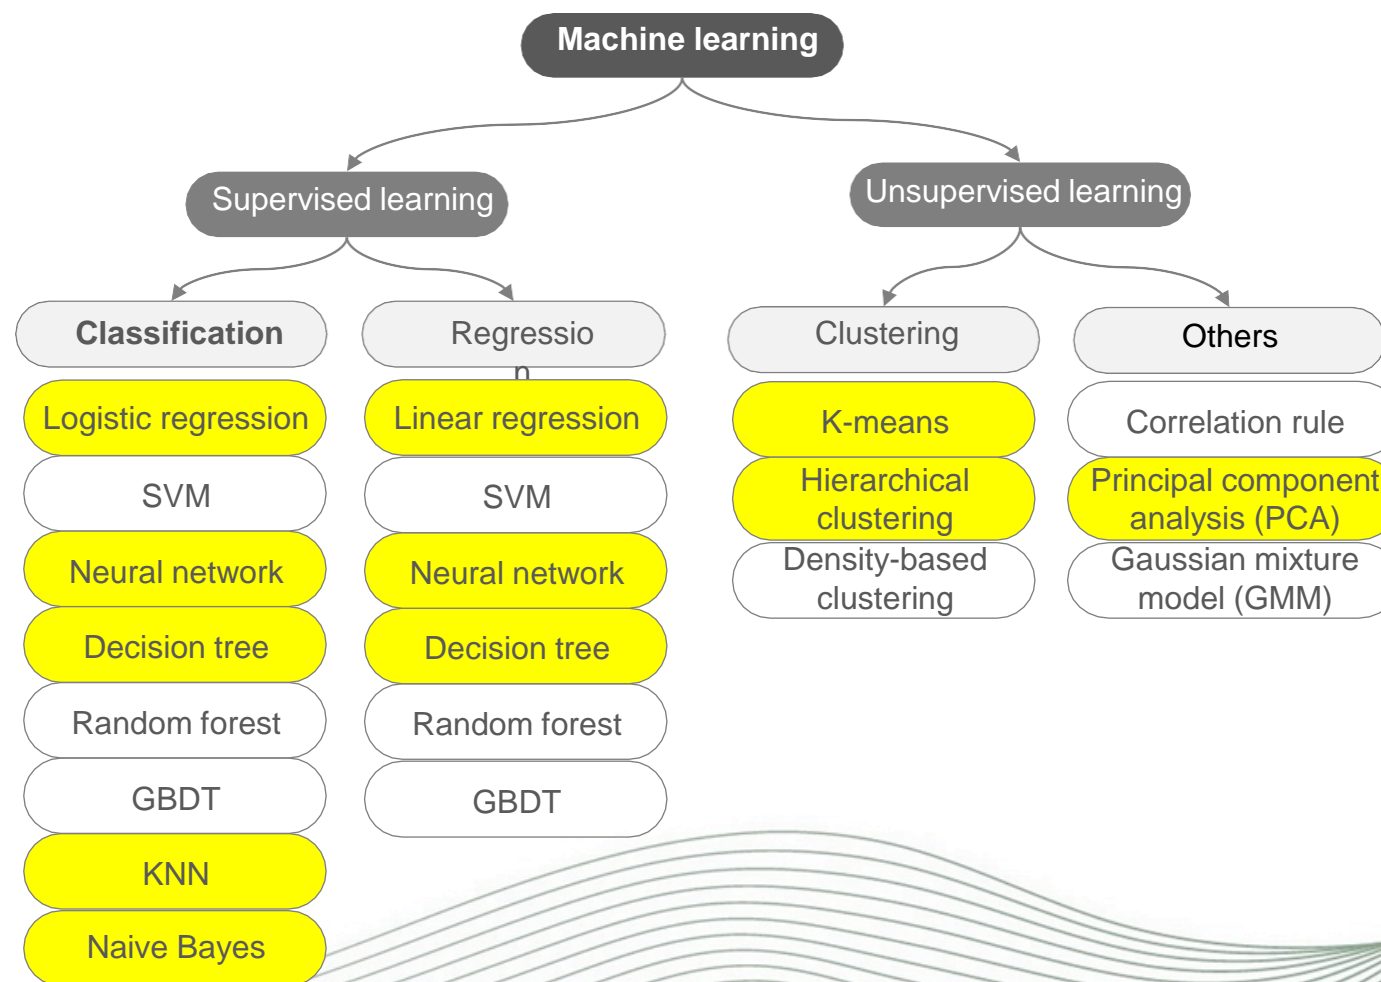
- Após a conclusão deste módulo, você será capaz de:
  - Descrever a diferença entre as redes neurais tradicionais e o aprendizado profundo;
  - Compreender a arquitetura de redes neurais profundas como a CNN
  - Conhecer diferentes redes neurais de aprendizado profundo





# IA

# Revisão: Algoritmos de Machine Learning







# Introdução às Redes Neurais: Deep Learning

- **Introdução ao Aprendizado Profundo**
- Rede Neural Convolucional (CNN)
- Outras redes de aprendizado profundo



UNIVERSIDADE  
ESTADUAL DO CEARÁ



MINISTÉRIO DA  
CIÊNCIA, TECNOLOGIA  
E INOVAÇÃO





# IA

## Introdução

- Como um modelo baseado no aprendizado de recursos não supervisionado e no aprendizado de hierarquia de recursos, o aprendizado profundo tem grandes vantagens em campos como visão computacional, reconhecimento de fala e processamento de linguagem natural.

### Aprendizado de máquina tradicional

Baixos requisitos de hardware no computador: Dada a quantidade limitada de computação, o computador não precisa de uma GPU para computação paralela em geral.

Aplicável a treinamentos com uma pequena quantidade de dados e cujo desempenho não pode ser melhorado continuamente à medida que a quantidade de dados aumenta.

Detalhamento do problema nível a nível

Seleção manual de recursos

Recursos fáceis de explicar

### Deep Learning

Requisitos de hardware mais altos no computador: Para executar operações matriciais em dados massivos, o computador precisa de uma GPU para executar computação paralela.

O desempenho pode ser alto quando parâmetros de peso de alta dimensão e dados de treinamento maciços são fornecidos.

Aprendizagem E2E

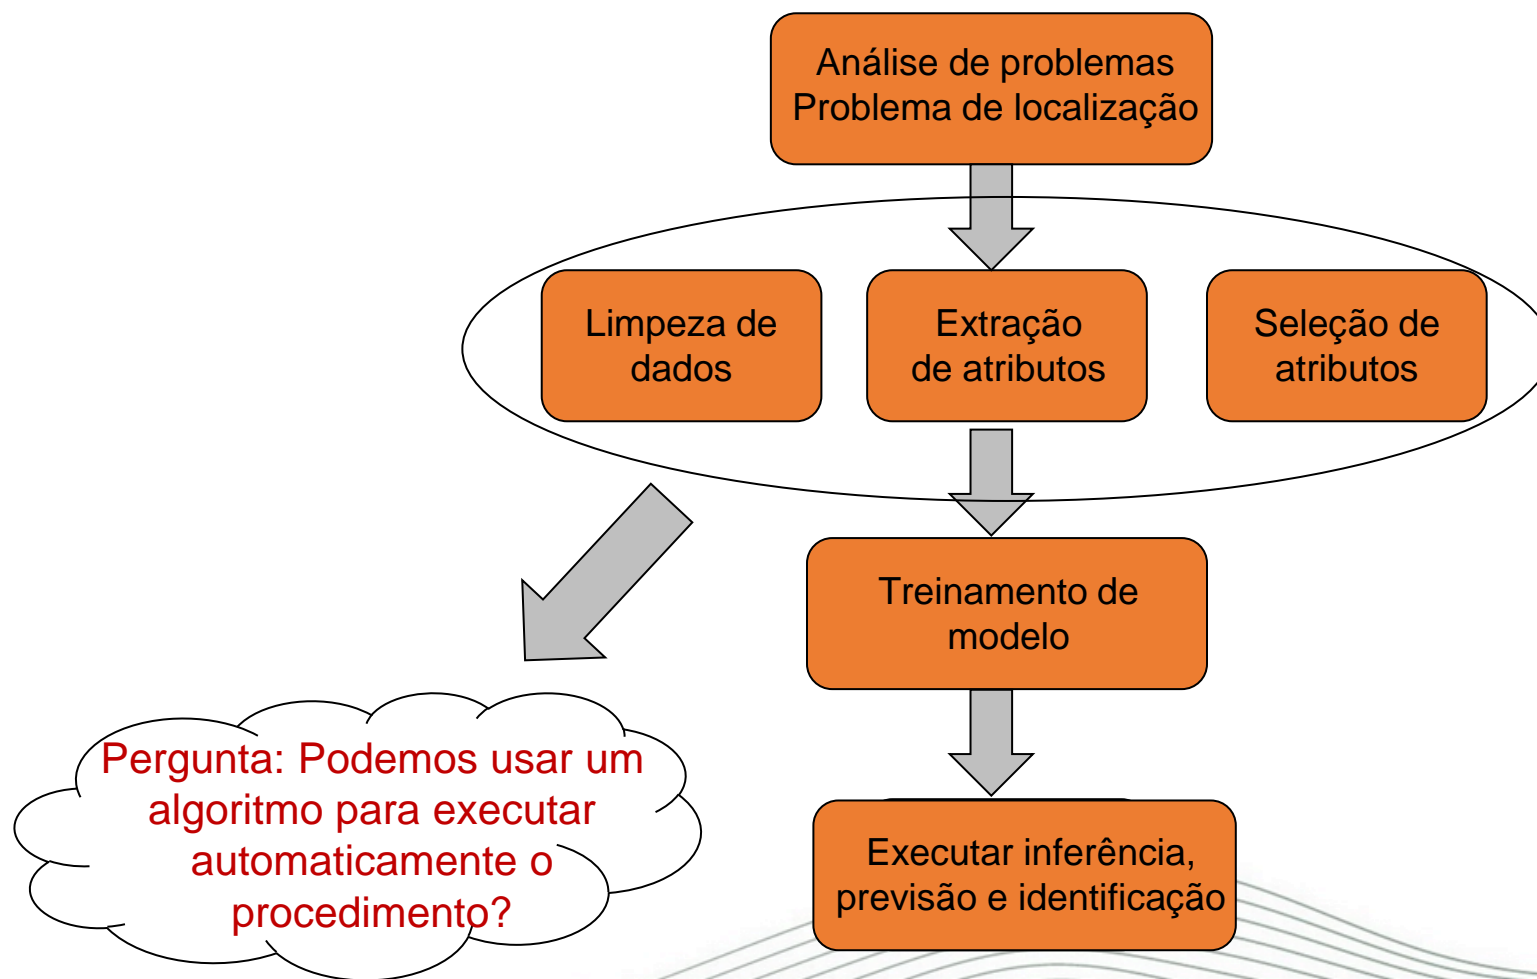
Extração automática de recursos baseada em algoritmo

Recursos difíceis de explicar



# IA

## Aprendizado de máquina tradicional








# IA


## Deep Learning

- Geralmente, a arquitetura de aprendizagem profunda é uma rede neural profunda. "Profundo" em "aprendizagem profunda" refere-se ao número de camadas da rede neural.

Simple Neural Network



Deep Learning Neural Network



● Input Layer

● Hidden Layer

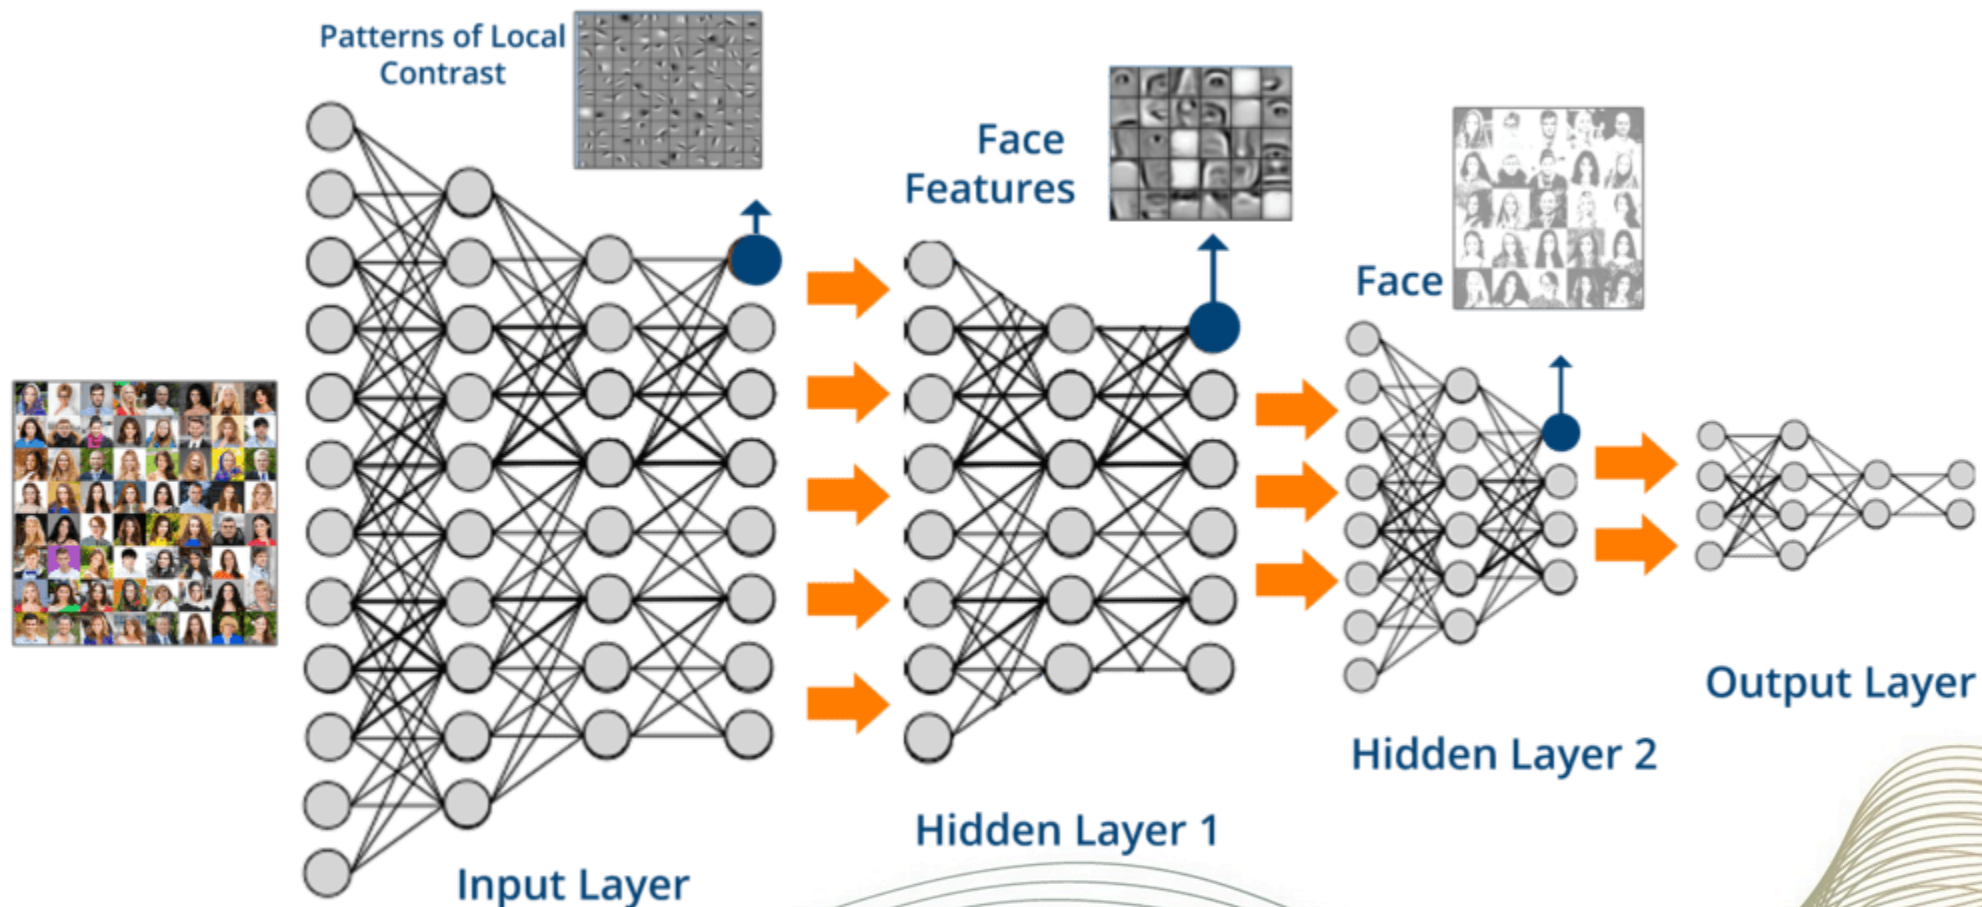
● Output Layer





# IA


## Exemplo de Aprendizado Profundo





# Introdução às Redes Neurais: Deep Learning

- Introdução ao Aprendizado Profundo
- **Rede Neural Convolucional (CNN)**
- Outras redes de aprendizado profundo



UNIVERSIDADE  
ESTADUAL DO CEARÁ



MINISTÉRIO DA  
CIÊNCIA, TECNOLOGIA  
E INOVAÇÃO






# IA

## Introdução

- Na década de 1960, Hubel e Wiesel estudaram os neurônios do córtex dos gatos usados para sensibilidade local e seleção de direção e descobriram que sua estrutura de rede única poderia simplificar as redes neurais de feedback. Eles então propuseram a CNN.
- Agora, a CNN tornou-se um dos principais assuntos de pesquisa em muitos campos científicos, especialmente no campo da classificação de padrões.
- A rede é amplamente utilizada porque pode evitar o pré-processamento complexo de imagens e inserir diretamente imagens originais.



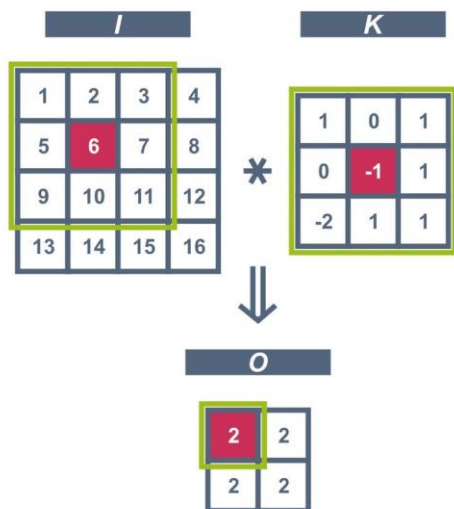




# IA

## Rede Neural Convolucional

- Uma Rede Neural Convolucional (CNN) é uma rede neural feedforward. Seus neurônios artificiais podem responder **a unidades circunvizinhas dentro de uma faixa de cobertura**.
- A CNN se destaca no processamento de imagens. Ele inclui uma **camada convolucional**, uma **camada de agrupamento** e uma **camada totalmente conectada**.




camada convolucional



camada de agrupamento  
(pooling)

Average Pool

Filter - (2 x 2)  
Stride - (2, 2)



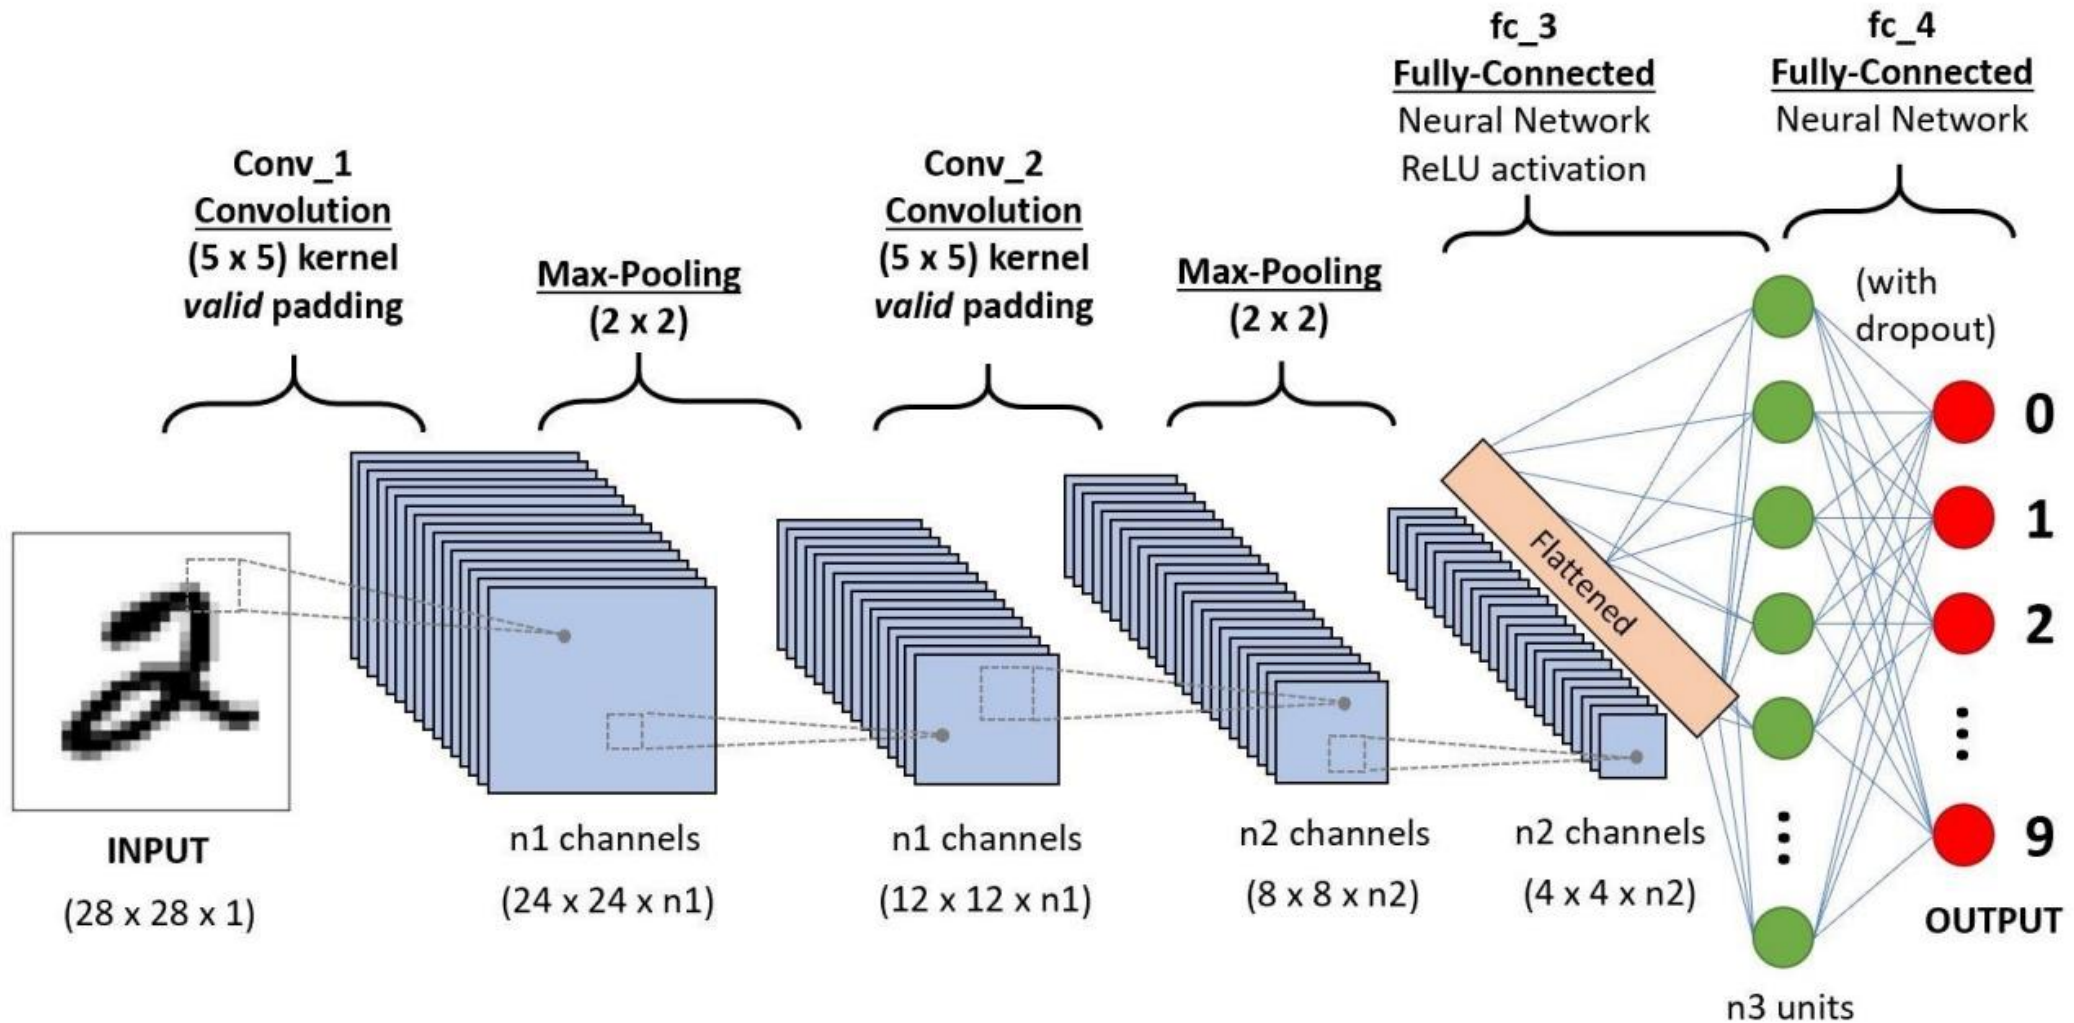
camada de totalmente conectada





# IA

## Exemplo






# IA

## Operações comuns no CNN - Convolução

- Definição:** representação matemática de como um sistema linear opera sobre um sinal.

$$g(x, y) = \sum_{s=-a}^a \sum_{t=-b}^b w(s, t) f(x + s, y + t)$$


Recorte



Substituir por:

$$g(2,2) = w(-1,-1)f(1,1) + w(0,-1)f(2,1) + \dots + w(1,1)f(3,3)$$

Mascara





# IA

## Demonstração do cálculo da convolução

1 <sub>x1</sub>	1 <sub>x0</sub>	1 <sub>x1</sub>	0	0
0 <sub>x0</sub>	1 <sub>x1</sub>	1 <sub>x0</sub>	1	0
0 <sub>x1</sub>	0 <sub>x0</sub>	1 <sub>x1</sub>	1	1
0	0	1	1	0
0	1	1	0	0

Image

4		


Convolved  
Feature



# IA

## Agrupamento

- O agrupamento combina unidades próximas para reduzir o tamanho da entrada na próxima camada, reduzindo as dimensões.
- Tipos comuns:
  - **agrupamento máximo**: o valor máximo em uma pequena área quadrada é selecionado como o representante dessa área,
  - **agrupamento médio**: o valor médio é selecionado como o representante dessa área








# IA

## Exemplo de Pooling





# IA

## Camada Completamente Conectada

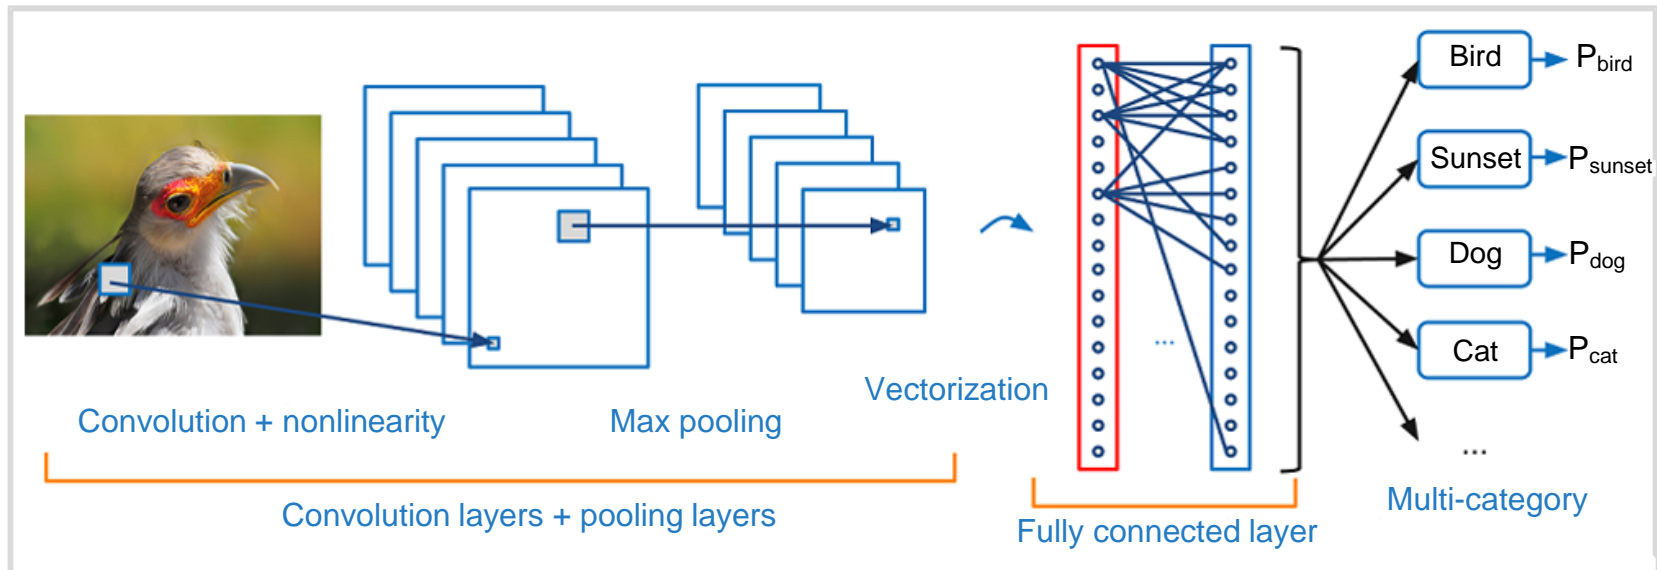
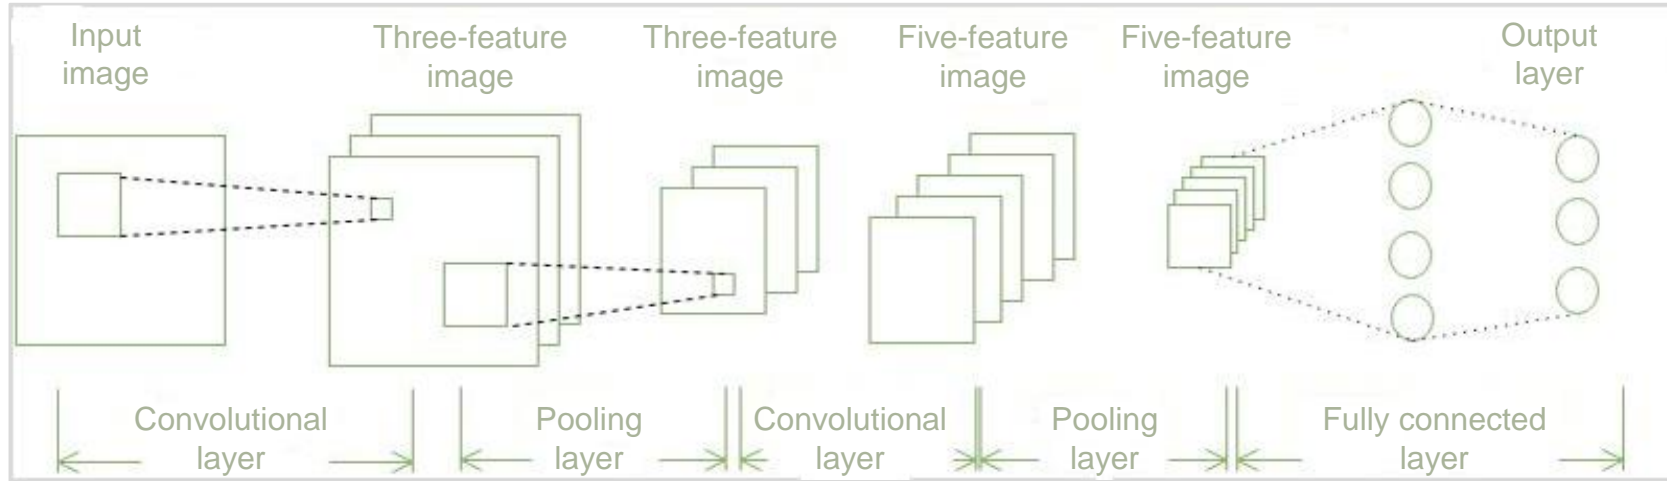
- A camada totalmente conectada é essencialmente um classificador.
- As características extraídas na camada convolucional e na camada de agrupamento são achatadas e colocadas na camada totalmente conectada para produzir e classificar os resultados.
- Geralmente, a função **Softmax** é usada como a função de ativação da camada de saída final totalmente conectada para combinar todos os recursos locais em recursos globais e calcular a pontuação de cada tipo.

$$\sigma(\mathbf{z})_j = \frac{e^{z_j}}{\sum_k e^{z_k}}$$



# IA

## Arquitetura de uma Rede Convolucional





# IA

## Principais Conceitos da CNN

- **Campo receptivo local:** É geralmente considerado que a percepção humana do mundo exterior é do local para o global. As correlações espaciais entre pixels locais de uma imagem são mais próximas do que entre pixels distantes. Portanto, cada neurônio não precisa conhecer a imagem global. Ele só precisa conhecer a imagem local. As informações locais são combinadas em um nível mais alto para gerar informações globais.
- **Compartilhamento de parâmetros:** Um ou mais filtros/kernels podem ser usados para digitalizar imagens de entrada. Os parâmetros transportados pelos filtros são pesos. Em uma camada verificada por filtros, cada filtro usa os mesmos parâmetros durante a computação ponderada. O compartilhamento de peso significa que, quando cada filtro verifica uma imagem inteira, os parâmetros do filtro são fixos.

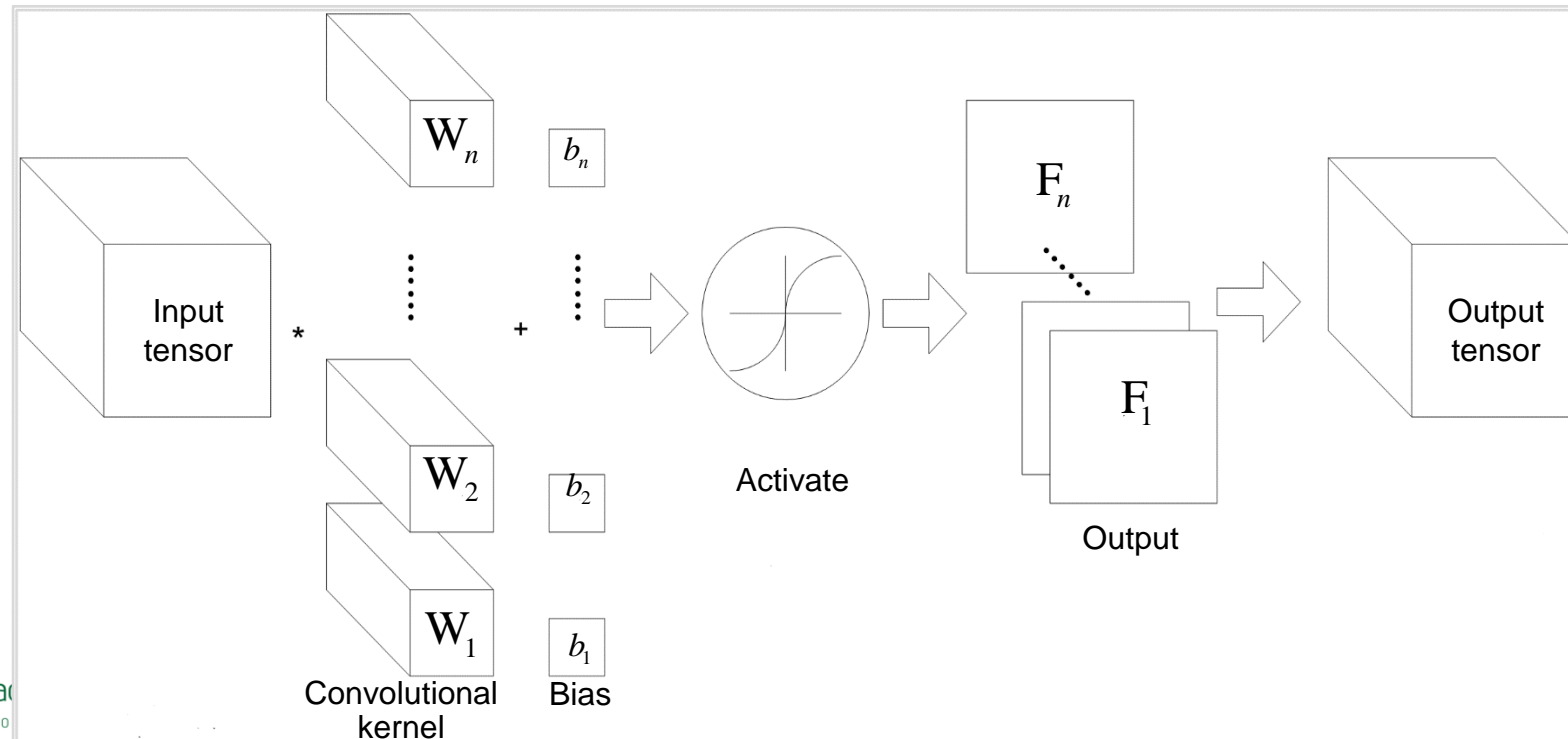




# IA

## Camada Convolutacional


- A arquitetura básica de uma CNN é a convolução multicanal que consiste em múltiplas convoluções únicas. A saída da camada anterior (ou a imagem original da primeira camada) é usada como a entrada da camada atual. Ele é então envolvido com o filtro na camada e serve como a saída dessa camada. O núcleo de convolução de cada camada é o peso a ser aprendido. Semelhante ao FCN, após a conclusão da convolução, o resultado deve ser tendencioso e ativado por meio de funções de ativação antes de ser inserido na próxima camada.





# Introdução às Redes Neurais: Deep Learning

- Introdução ao Aprendizado Profundo
- Rede Neural Convolucional (CNN)
- Outras redes de aprendizado profundo



UNIVERSIDADE  
ESTADUAL DO CEARÁ




MINISTÉRIO DA  
CIÊNCIA, TECNOLOGIA  
E INOVAÇÃO





- A Rede Neural Recorrente (**RNN – Recurrent Neural Network**) é uma rede neural que captura informações dinâmicas em dados sequenciais através de conexões periódicas de nós de camada oculta. Ele pode classificar dados sequenciais.
- Ao contrário de outras redes neurais avançadas, a RNN pode manter um estado de contexto e até mesmo armazenar, aprender e expressar informações relacionadas em janelas de contexto de qualquer comprimento.
- Diferente das redes neurais tradicionais, não se limita ao limite do espaço, mas também suporta sequências de tempo. Em outras palavras, há um lado entre a camada oculta do momento atual e a camada oculta do momento seguinte.
- O RNN é amplamente utilizado em cenários relacionados a sequências, como vídeos que consistem em quadros de imagens, áudio que consiste em cliques e frases que consistem em palavras.





# IA

## Arquitetura de rede neural recorrente

- $X_t$  é a entrada da sequência de entrada no tempo  $t$ .
- $S_t$  é a unidade de memória da sequência no tempo  $t$  e armazena em cache as informações anteriores.

$$S_t = \tanh(UX_t + WS_{t-1}).$$

- $O_t$  é a saída da camada oculta da sequência no tempo  $t$ .
$$O_t = \tanh(VS_t)$$
- $O_t$  depois de através de várias camadas ocultas, ele pode obter a saída final da sequência no momento  $t$ .

- $X_t$  é a entrada da sequência de entrada no tempo  $t$ .
- $S_t$  é a unidade de memória da sequência no tempo  $t$  e armazena em cache as informações anteriores.

$$S_t = \tanh(UX_t + WS_{t-1}).$$

- $O_t$  é a saída da camada oculta da sequência no tempo  $t$ .
$$O_t = \tanh(VS_t)$$
- $O_t$  depois de através de várias camadas ocultas, ele pode obter a saída final da sequência no momento  $t$ .







# IA

## Tipos de RNN


one to one




one to many




many to one



many to many

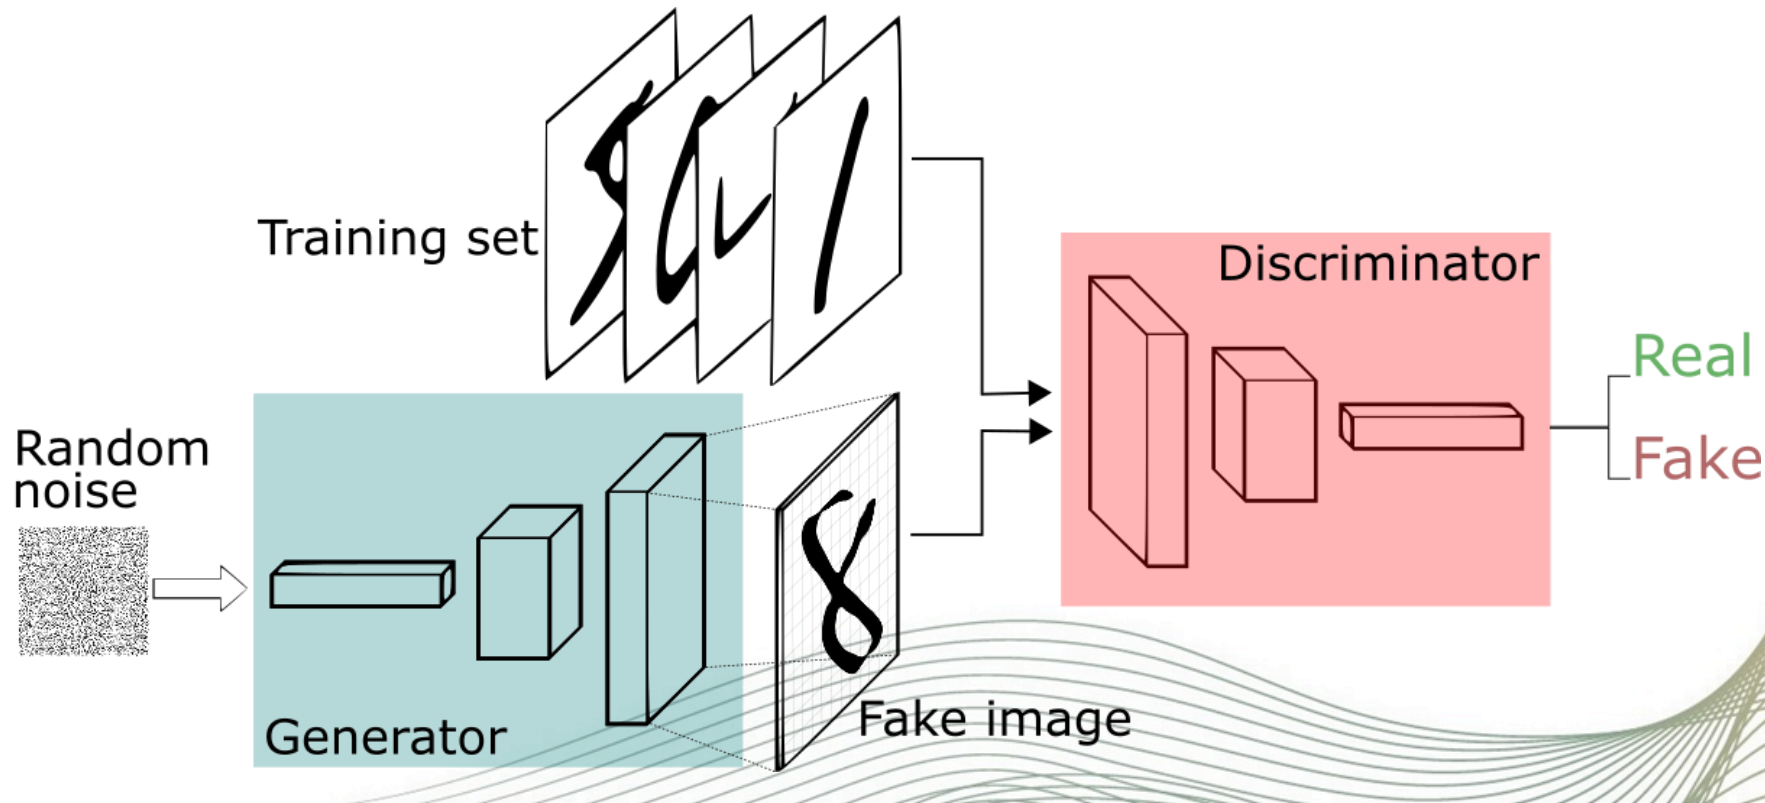


many to many





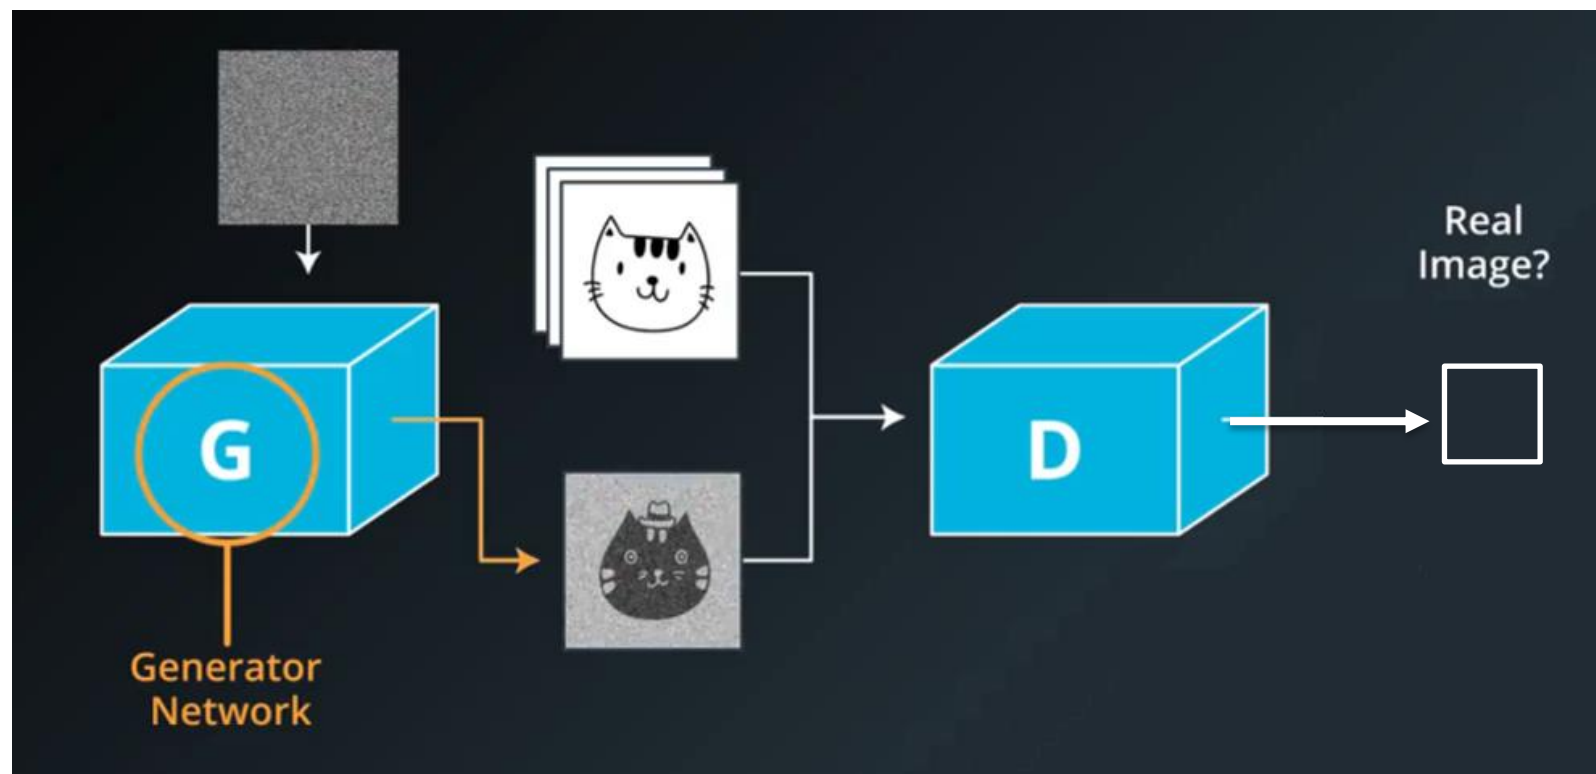
- A Rede Adversária Generativa (**GAN - Generative Adversarial Network**) é uma estrutura que treina o gerador G e o discriminador D através do processo contraditório.





# IA

## Exemplo





- Através do processo contraditório, o discriminador pode dizer se a amostra do gerador é falsa ou real. O GAN adota um algoritmo BackPropagation maduro.
  - **Gerador G:** A entrada é o ruído  $z$ , que está em conformidade com a distribuição de probabilidade prévia selecionada manualmente, como a distribuição par e a distribuição gaussiana. O gerador adota a estrutura de rede do perceptron multicamada (MLP), usa parâmetros de estimativa de máxima verossimilhança (MLE) para representar o mapeamento derivável  $G(z)$  e mapeia o espaço de entrada para o espaço amostral.
  - **Discriminador D:** A entrada é a amostra real  $x$  e a amostra falsa  $G(z)$ , que são marcadas como reais e falsas, respectivamente. A rede do discriminador pode usar os parâmetros de transporte MLP. A saída é a probabilidade  $D(G(z))$  que determina se a amostra é uma amostra real ou falsa.
- O GAN pode ser aplicado a cenários como geração de imagem, geração de texto, aprimoramento de fala, super-resolução de imagem.






# IA


## Modelo Generativo e Modelo Discriminativo


- Rede generativa
  - Gera dados de exemplo
    - **Entrada:** vetor de ruído branco Gaussiano  $z$
    - **Saída:** vetor de dados de amostra  $x$
- Rede de discriminadores
  - Determina se os dados de exemplo são reais
    - **Entrada:** dados de amostra reais  $x_{real}$  e dados de amostra gerados  $x = G(z)$
    - **Saída:** probabilidade que determina se a amostra é real

$$x = G(z; \theta^G)$$



$$y = D(x; \theta^D)$$





# Introdução às Redes Neurais: Perceptron Simples

- **Prática DeepLearning**



UNIVERSIDADE  
ESTADUAL DO CEARÁ



MINISTÉRIO DA  
CIÊNCIA, TECNOLOGIA  
E INOVAÇÃO



# Dúvidas?

Módulo de Inteligência Artificial



UNIVERSIDADE  
ESTADUAL DO CEARÁ



Instituto Iracema  
PESQUISA E INOVAÇÃO



MINISTÉRIO DA  
CIÊNCIA, TECNOLOGIA  
E INOVAÇÃO

